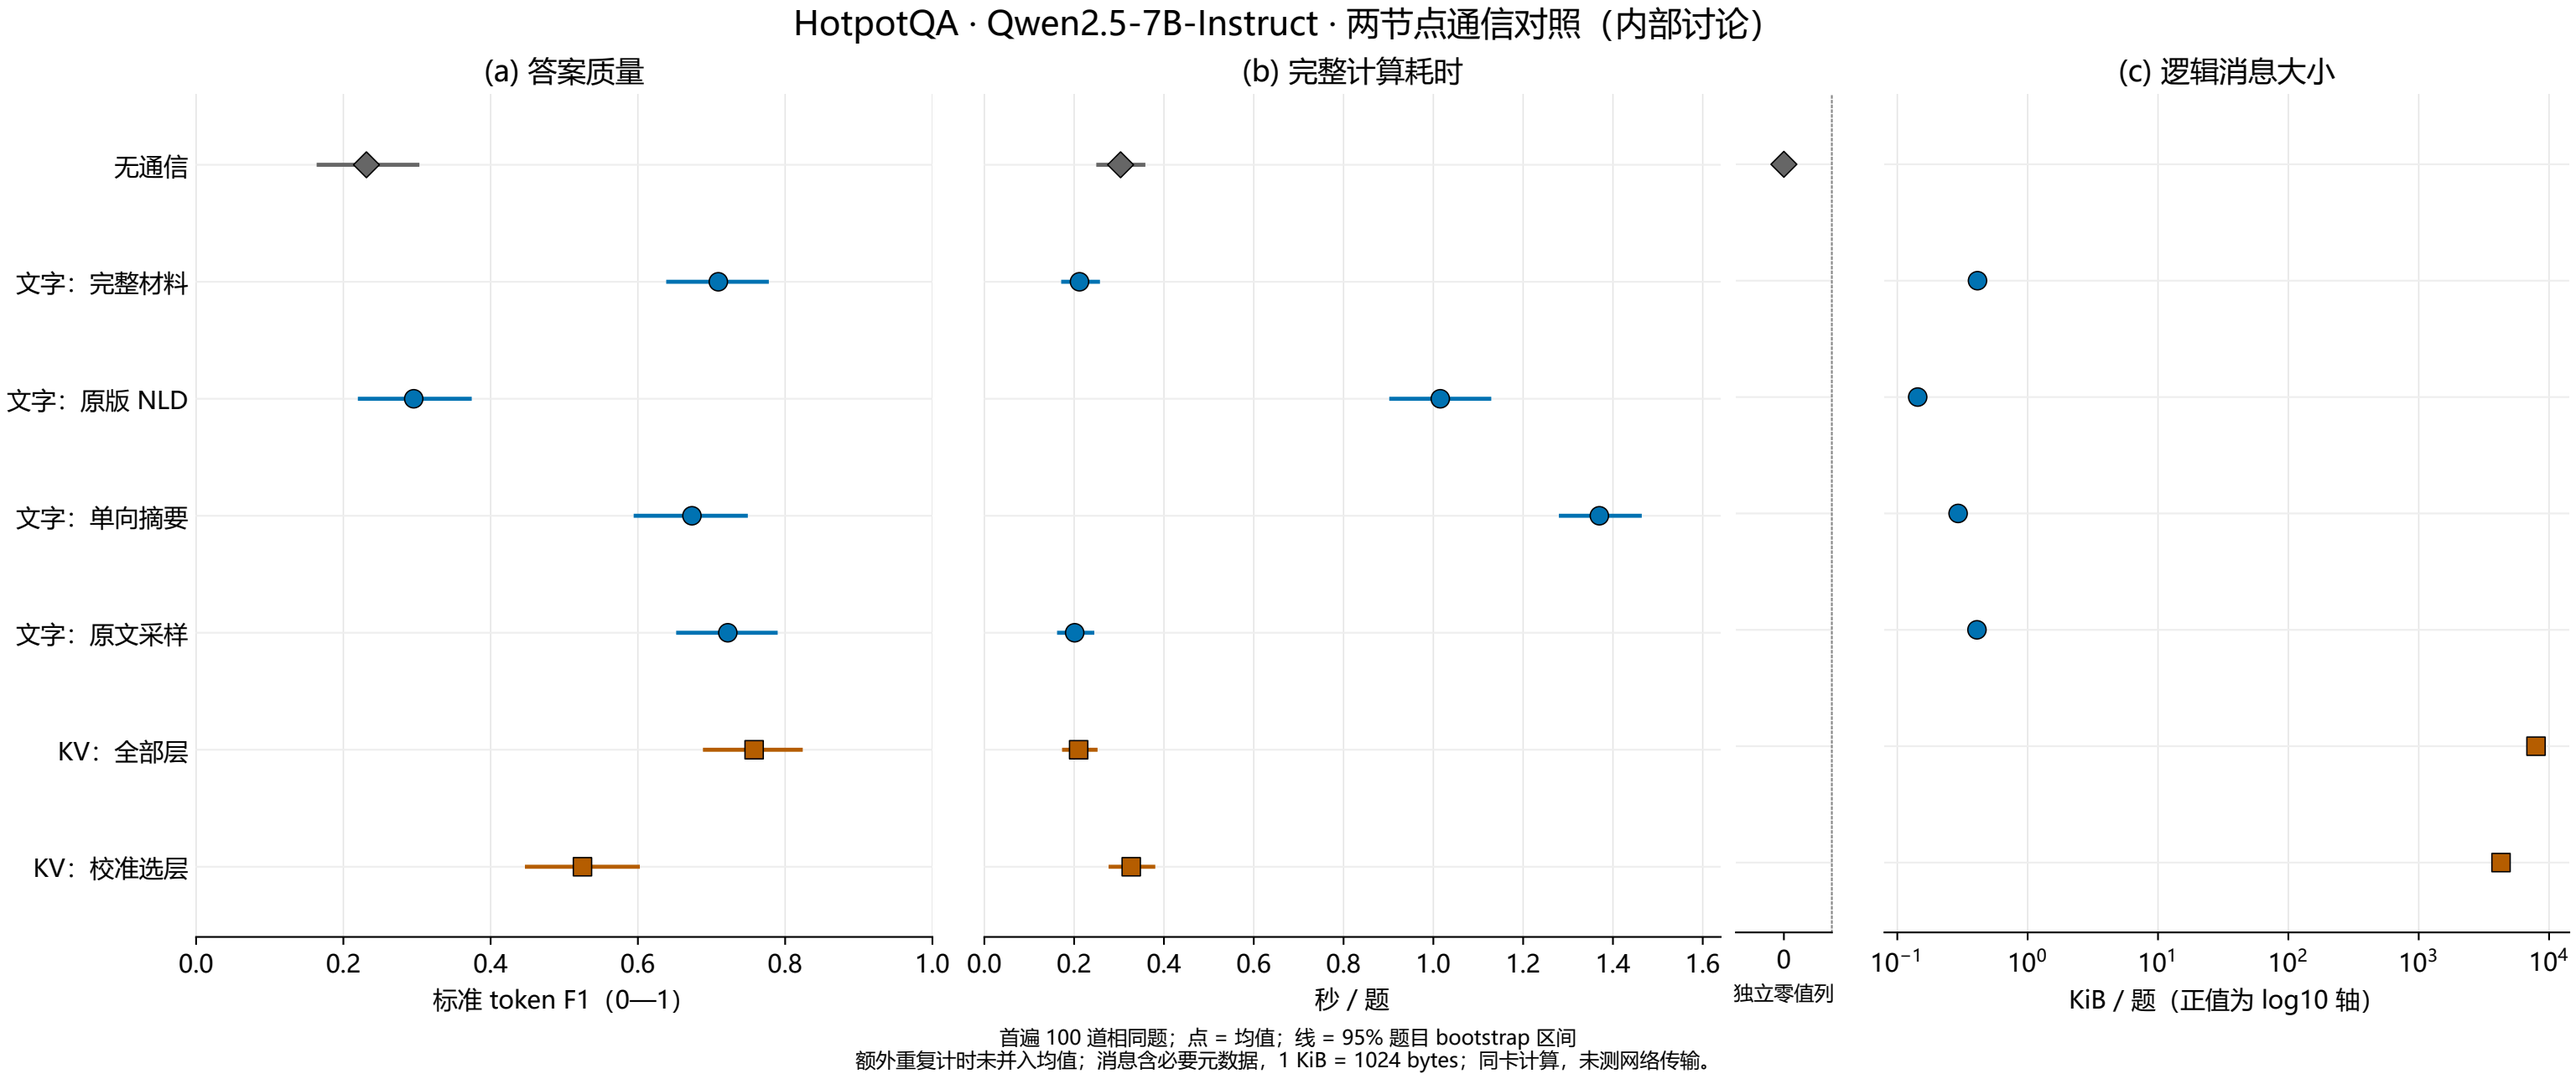

HotpotQA · Qwen2.5-7B-Instruct · 两节点通信对照（内部讨论）
(a) 答案质量
(b) 完整计算耗时
(c) 逻辑消息大小
无通信
文字：完整材料
文字：原版 NLD
文字：单向摘要
文字：原文采样
KV：全部层
KV：校准选层
0.0
0.2
0.4
0.6
0.8
1.0
标准 token F1（0—1）
0.0
0.2
0.4
0.6
0.8
1.0
1.2
1.4
1.6
秒 / 题
0
独立零值列
10^{-1}
10^{0}
10^{1}
10^{2}
10^{3}
10^{4}
KiB / 题（正值为 log10 轴）
首遍 100 道相同题；点 = 均值；线 = 95% 题目 bootstrap 区间
额外重复计时未并入均值；消息含必要元数据，1 KiB = 1024 bytes；同卡计算，未测网络传输。